Figura 1: Enter Caption

Universidade Federal de São Carlos

Centro de Ciências Exatas e de Tecnologia

Departamento de Estatística

# Determinantes Socioeconômicos do Voto nas Eleições de 2000

Arthur Pereira Gon

# Introdução

O conjunto de dados em estudo contém informações sobre o segundo turno das eleições presidenciais de 2002 do Brasil e características de municípios da região sudeste deste país. As variáveis encontradas no banco de dados foram:

- Munícípio;
- UF: Unidade da Federação;
- Nome: nome do município;
- CodMunic: código do município;
- Oposicao : votos recebidos pelo candidato da oposição;
- Situacao: votos recebidos pelo candidato da situação;
- OposicaGanha: 1 se oposição ganha e 0 se situação ganha no município;
- IDHM: IDH municipal;
- IDHR: IDH renda;
- IDHL: IDH longevidade;
- IDHE: IDH educação;
- Alfab91: proporção de alfabetizados entre as pessoas com 15 anos ou mais em 2000;
- Alfab00: proporção de alfabetizados entre as pessoas com 15 anos ou mais em 1992;
- Medico91: razão entre o total de médicos residentes no município e o total de habitantes, em 1991;
- Medico00: razão entre o total de médicos residentes no município e o total de habitantes, em 2000;
- DistBrasilia: distância entre o município e Brasília (em km);
- DistCapital: distância entre o município e a capital do estado;
- Pop2000: População em 2000;
- Propmasc2000: população masculina em 2000;
- PocentagemHomens: porcentagem de homens na população, em 2000

De acordo com o que foi apresentado, pode-se ter o interesse em encontrar características específicas entre os municípios brasileiros, as quais podem se relacionar com índices econômicos, de infraestrutura, de bem-estar, entre outros.

# Objetivo

O objetivo do trabalho é analisar como variáveis socioeconômicas (IDHM, IDHL, IDHE), de saúde (Medico00), indicadores educacionais (Alfab00) e índices populacionais (Pop200) influenciam a predominância de votos na Oposição (Lula) ou Situação (José Serra), utilizando Análise Fatorial (AF) para reduzir a dimensionalidade e facilitar a interpretação do comportamento dessas variáveis.

# Material e Métodos

A primeira parte para a realização do estudo é identificar as variáveis que fazem mais sentido e que podem fornecer maiores informações para o objetivo proposto. Com isso, as seguintes variáveis foram escolhidas para o método que será usado:

- IDHM
- IDHL
- IDHE
- Alfab00
- Medico00
- Pop2000

Portanto, foram usadas variáveis do âmbito socioeconômico e educacional (IDHM, IDHL, IDHE e Alfab00), do âmbito demográfico (Pop2000) e da área da saúde (Medico00).

# Resultados

## Análise descritiva

Tabela 1: Médias e desvios padrões das variáveis analisadas

| Variável | Média | Desvio Padrão |
|---|---|---|
| IDHM | 0.74 | 0.05 |
| IDHL | 0.75 | 0.05 |
| IDHE | 0.82 | 0.06 |
| Alfab00 | 85.00 | 7.26 |
| Medico00 | 0.41 | 0.66 |
| Pop2000 | 43464.83 | 307988.73 |

Verificando a tabela de médias e desvios-padrões, vemos que os desvios são muito distantes uns dos outros, assim devemos utilizar a matriz de correlação para continuarmos nossa análise fatorial.

## Matriz de correlação

Tabela 2: Matriz de Correlação entre as Variáveis

| | IDHM | IDHL | IDHE | Alfab00 | Medico00 | Pop2000 |
|---|---|---|---|---|---|---|
| IDHM | 1.000 | 0.804 | 0.909 | 0.913 | 0.453 | 0.141 |
| IDHL | 0.804 | 1.000 | 0.568 | 0.611 | 0.227 | 0.020 |
| IDHE | 0.909 | 0.568 | 1.000 | 0.946 | 0.422 | 0.158 |
| Alfab00 | 0.913 | 0.611 | 0.946 | 1.000 | 0.376 | 0.131 |
| Medico00 | 0.453 | 0.227 | 0.422 | 0.376 | 1.000 | 0.253 |
| Pop2000 | 0.141 | 0.020 | 0.158 | 0.131 | 0.253 | 1.000 |

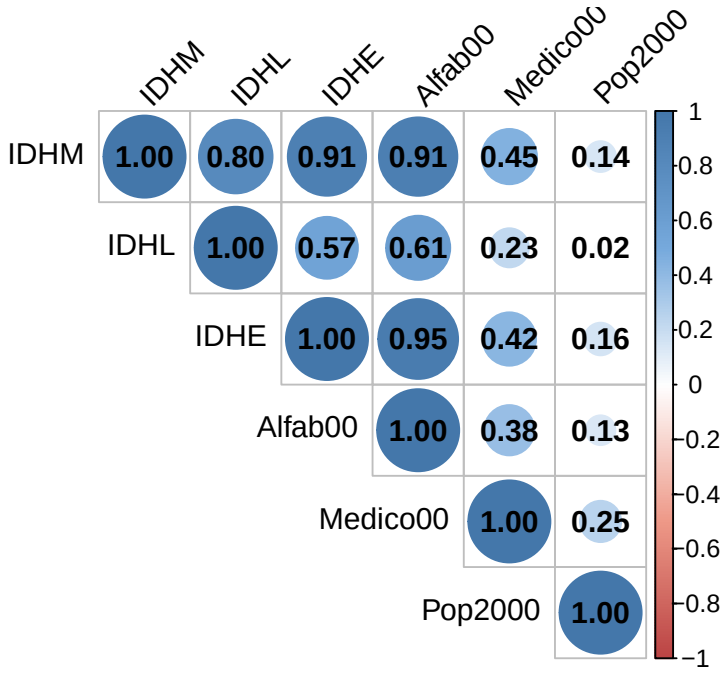


Figura 2: Gráfico das correlações entre as variáveis

A matriz de correlação indica que a variável Alfabetização (Alfab00) apresenta altas correlações tanto com IDHL (0.61) quanto com IDHE (0.95) e IDHM (0.91), o que pode ser um indício de que municípios com adolescentes mais alfabetizados tendem a ter maior IDH (IDHL, IDHE, IDHM).

Já os indicadores socioeconômicos, como IDHM, IDHL e IDHE, mostram correlações altas entre si, o que faz sentido pois mostram todos um nível de desenvolvimento da cidade estudada.

Além disso, a variável relacionada à população (Pop2000), possue correlações baixas com todas as outras variáveis, indicando que ela não se relaciona muito com as variáveis socioeconômicas, de saúde e de educação.

## Definição das dimensões

Tabela 3: Autovalores da Matriz de Correlação

| $\lambda_1$ | $\lambda_2$ | $\lambda_3$ | $\lambda_4$ | $\lambda_5$ | $\lambda_6$ |
|---|---|---|---|---|---|
| 3.6436 | 1.1029 | 0.6840 | 0.4905 | 0.0520 | 0.0270 |

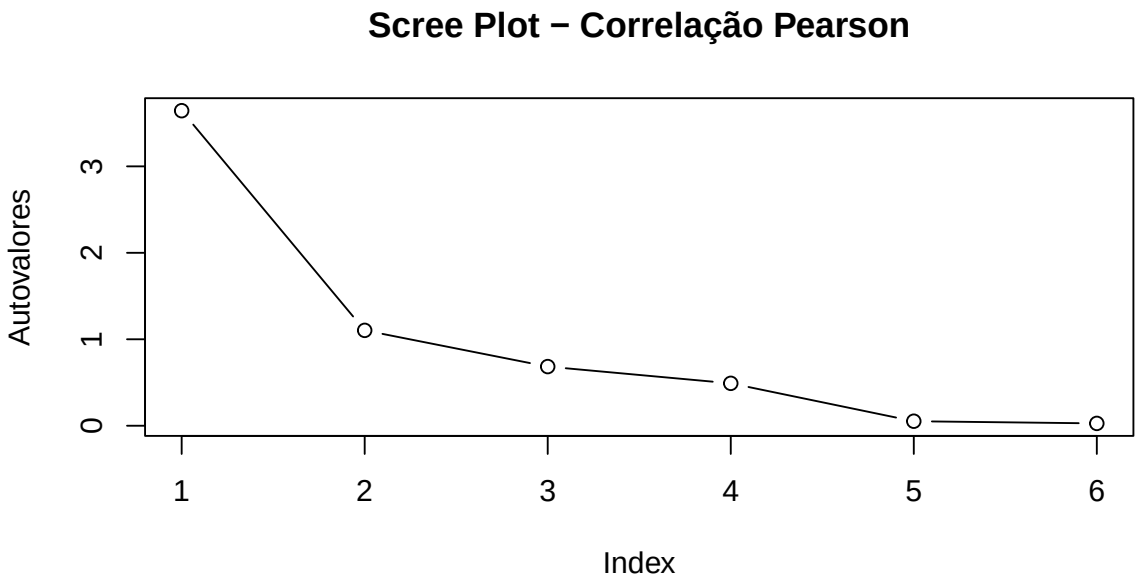


Figura 3: Scree plot dos autovalores

Como vamos definir que usaremos as dimensões que possuem autovalores maiores que 1, vamos fazer nossa análise fatorial com 2 dimensões com cargas fatoriais. Podemos verificar pelo scree plot que tem um "cotovelo" após o segundo autovalor associado, indicando também que o uso de duas dimensões parece ser adequado.

## Teste KMO

Tabela 5: Índice de Adequação da Amostra de Kaiser-Meyer-Olkin (KMO)

| Estatística | Valor |
|---|---|
| KMO Geral | 0.69 |
| MSA por Variável | |
| IDHM | 0.66 |
| IDHL | 0.56 |
| IDHE | 0.74 |
| Alfab00 | 0.83 |
| Medico00 | 0.66 |
| Pop2000 | 0.76 |

O teste KMO resultou em um valor de 0.69, indicando que a matriz de correlação tem uma adequação razoável para a realização de uma Análise Fatorial. Entre as variáveis analisadas, Alfab00 (0.83) e Pop2000 (0.76) tiveram os maiores valores de MSA, demonstrando que são as mais adequadas para a estrutura fatorial. Em contrapartida, IDHL (0.56) possui o MSA mais baixo, mas como todos tem MSA maior que 0.5, podemos continuar a análise fatorial sem maiores problemas.

Tabela 6: Estatísticas das cargas fatoriais

| | PC1 | PC2 |
|---|---|---|
| SS Loadings | 3.64 | 1.10 |
| Proporção da Variância | 0.61 | 0.18 |
| Variância Acumulada | 0.61 | 0.79 |
| Proporção Explicada | 0.77 | 0.23 |
| Proporção Acumulada | 0.77 | 1.00 |

Como as duas primeiras cargas fatoriais explicam 79% da variância total, podemos prosseguir com a análise fatorial, pois grande parte da variabilidade está sendo explicada nesse planejamento.

## Análise Fatorial

Tabela 7: Matriz de Cargas Padronizadas

| Variável | PC1 | PC2 | $h^2$ | $u^2$ | complexidade |
|---|---|---|---|---|---|
| IDHM | 0.98 | -0.10 | 0.98 | 0.024 | 1.0 |
| IDHL | 0.77 | -0.30 | 0.67 | 0.326 | 1.3 |
| IDHE | 0.94 | -0.04 | 0.88 | 0.120 | 1.0 |
| Alfab00 | 0.94 | -0.09 | 0.89 | 0.110 | 1.0 |
| Medico00 | 0.54 | 0.50 | 0.54 | 0.458 | 2.0 |
| Pop2000 | 0.21 | 0.86 | 0.78 | 0.215 | 1.1 |

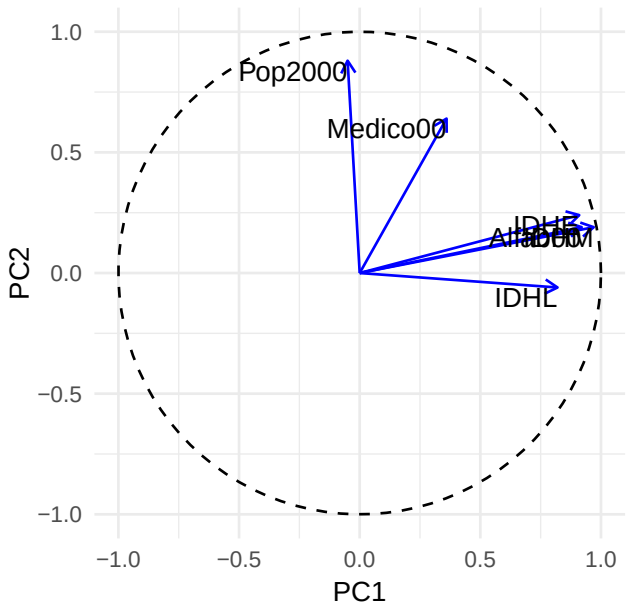


Figura 4: Gráfico das cargas fatoriais

Pode-se ver que todas as comunalidades das variáveis têm um valor maior que 0.50, mas com altos valores, como da variável "IDHM"(0.98), "Alfab00"(0.89) e "IDHE"(0.88). Analisando os valores das cargas fatoriais, no primeiro fator principal, as variáveis que estão mais associadas são "IDHM"(0.98), IDHL"(0.77), "IDHE"(0.94) e "Alfab00"(0.94), mostrando que o primeiro fator tem um valor socioeconômico para as suas observações. Enquanto isso, o segundo fator principal está associado à uma questão populacional, pois a variável "Pop2000"tem uma grande influência (0.86) neste fator. Sobre a variável "Medico00"podemos dizer que ela tem uma contribuição razoável para os dois fatores principais (0.54 e 0.50 respectivamente), pois para questões socioeconômicas, a saúde está relacionada diretamente nesse contexto, mas também como estamos falando de uma variável que está na forma de uma razão entre todos os habitantes, ela também está relacionada com o segundo fator principal, de características populacionais.

As interpretações obtidas através da Tabela 7 se confirmam com o gráfico das cargas fatoriais, o qual mostra as variáveis "IDHE", "IDHM"e "Alfa00"com valores significativos no primeiro fator, além disso elas estão bem próximas e na mesma direção, indicando correlação positiva. Já as variáveis "Pop2000"e "Medico00"possuem valores significativos para o segundo fator, evidenciando o que foi dito anteriormente. Podemos observar também que a variável "IDHL"está praticamente fazendo um ângulo de 90 graus com as duas variáveis citadas anteriormente, reforçando sobre a baixa correlação que existe entre elas.

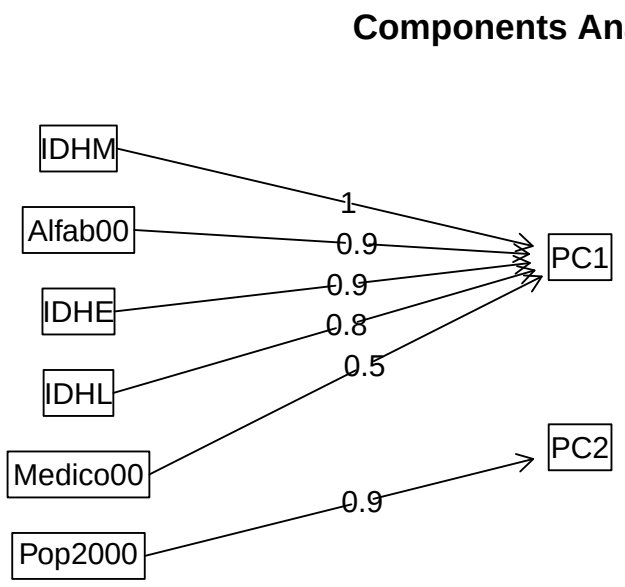


Figura 5: Diagrama de caminhos

A partir do diagrama de caminhos acima, mais uma vez confirmamos as análises feitas anteriormente sobre quais fatores explicam cada uma das variáveis.

## Interpretação dos escores

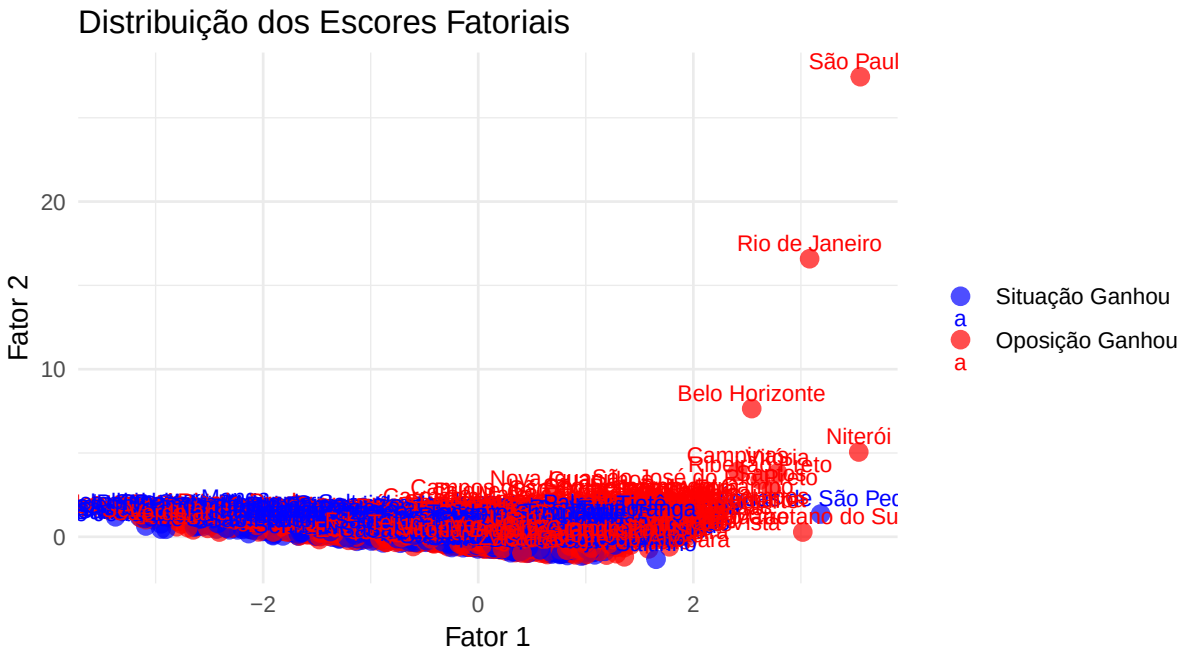


Figura 6: Gráfico dos escores fatoriais

Como no segundo fator principal vimos que a maior parte dele é explicado pela variável "Pop2000", notamos que as observações que estão com valores maiores nesse fator são: São Paulo, Rio de Janeiro e Belo Horizonte, que são as capitais dos estados da região Sudeste e assim, as mais populosas. Em relação ao primeiro fator principal, que identificamos como um índice de desenvolvimento socioeconômico, vemos que há uma separação das observações, sendo as cidades com valores mais positivos para esse fator as cidades nas quais a oposição ganhou na eleição de 2002. Enquanto isso, as cidades que aparecem do lado negativo do fator principal 1 são na maior parte as cidades em que a situação ganhou na eleição de 2002.

## Primeiro fator principal

Vamos comparar a média das variáveis com algumas observações para compararmos os resultados.

### Maiores valores

São Paulo (SP)

Tabela 8: Valores das Variáveis para São Paulo e Média Geral

| Cidade | Oposição Ganha | IDHM | IDHL | IDHE | Alfab00 | Medico00 |
|---|---|---|---|---|---|---|
| São Paulo | 1 | 0.841 | 0.761 | 0.919 | 95.111 | 2.703 |
| Média | - | 0.740 | 0.750 | 0.820 | 85.000 | 0.410 |

Niterói (RJ)

Tabela 9: Valores das Variáveis para Niterói e Média Geral

| Cidade | Oposição Ganha | IDHM | IDHL | IDHE | Alfab00 | Medico00 |
|---|---|---|---|---|---|---|
| Niterói | 1 | 0.762 | 0.717 | 0.884 | 92.806 | 0.892 |
| Média | - | 0.740 | 0.750 | 0.820 | 85.000 | 0.410 |

Portanto, nas duas cidades citadas acima (São Paulo e Niterói), a oposição ganha e elas possuem média maior quando comparadas com a média geral em praticamente todas as variáveis.

**Menores Valores**

Setubinha (MG)

Tabela 10: Valores das Variáveis para Setubinha e Média Geral

| Cidade | Oposição Ganha | IDHM | IDHL | IDHE | Alfab00 | Medico00 |
|---|---|---|---|---|---|---|
| Setubinha | 0 | 0.568 | 0.607 | 0.608 | 53.918 | 0.000 |
| Média | - | 0.740 | 0.750 | 0.820 | 85.000 | 0.410 |

Fruta de Leite (MG)

Tabela 11: Valores das Variáveis para Fruta de Leite e Média Geral

| Cidade | Oposição Ganha | IDHM | IDHL | IDHE | Alfab00 | Medico00 |
|---|---|---|---|---|---|---|
| Fruta de Leite | 0 | 0.586 | 0.701 | 0.613 | 55.207 | 0.000 |
| Média | - | 0.740 | 0.750 | 0.820 | 85.000 | 0.410 |

Neste caso, tanto Setubinha quanto Fruta de Leite ficaram com médias abaixo, quando comparadas com a média geral, para todas as variáveis, além disso, nessas cidades a oposição não ganha.

É interessante observar essas situações pois, as cidades com índices socioeconômicos maiores, como São Paulo e Niterói, obtiveram um resultado favorável em relação à oposição. Já cidades com índices socioeconômicos abaixo da média, como Setubinha e Fruta de Leite, tiveram um resultado desfavorável quando se trata da oposição, ou seja, foram favoráveis à situação.

## Segundo Fator Principal

### Maiores Valores

São Paulo (SP)

Tabela 12: Comparação da População de São Paulo com a Média Geral (Pop2000)

| Cidade | Pop2000 |
|---|---|
| São Paulo | 10434252 |
| Média | 43464.83 |

Rio de Janeiro (RJ)

Tabela 13: Comparação da População do Rio de Janeiro com a Média Geral (Pop2000)

| Cidade | Pop2000 |
|---|---|
| Rio de Janeiro | 5857904 |
| Média | 43464.83 |

Observando agora os maiores valores para o segundo fator principal, selecionamos duas cidades, São Paulo e Rio de Janeiro, as quais possuem grandes populações, sendo em ambos os casos, maiores do que a média da população e nessas cidades a oposição ganhou.

### Menores Valores

Saltinho (SP)

Tabela 14: Comparação da População de Saltinho com a Média Geral (Pop2000)

| Cidade | Pop2000 |
|---|---|
| Saltinho | 5799 |
| Média | 43464.83 |

No caso de uma cidade com população pequena, foi a cidade de Saltinho, a qual possui população bem abaixo da média geral e está na situação de que a oposição não ganhou.

A conclusão para o segundo fator principal se assemelha à do primeiro fator, evidenciando que cidades mais populosas tendem, em primeira vista, à votar na oposição, o contrário tende a acontecer para cidade menos populosas, como Saltinho, na qual a oposição não ganhou.

# Verificando a influência dos fatores principais na variável "OposicaoGanha"

Após fazermos a análise fatorial, queremos verificar se o valor do escore do município influencia na escolha da cidade em um eleitor no ano de 2002. Para isso, vamos fazer um boxplot com os valores dos escores fatoriais em ambas dimensões e verificar se há uma diferença entre as duas populações.

## Primeiro fator principal

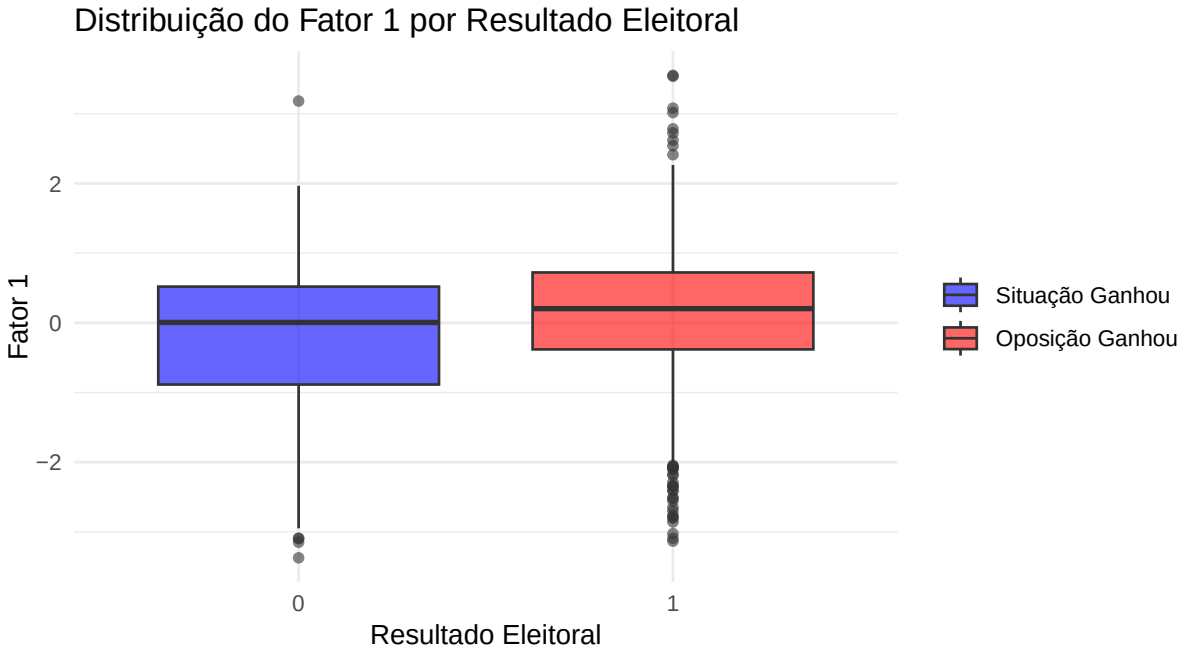


Figura 7: Boxplot dos escores fatoriais em relação ao primeiro fator principal

Tabela 4: Autovetores Correspondentes

| | $IDHM$ | $IDHL$ | $IDHE$ | $Alfab00$ | $Medico00$ | $Pop2000$ |
|---|---|---|---|---|---|---|
| $x_1$ | -0.5148 | 0.0982 | -0.0500 | 0.0594 | -0.1939 | 0.8257 |
| $x_2$ | -0.4008 | 0.2842 | -0.2160 | 0.7695 | 0.0321 | -0.3446 |
| $x_3$ | -0.4909 | 0.0354 | -0.0258 | -0.4407 | -0.6180 | -0.4253 |
| $x_4$ | -0.4917 | 0.0897 | -0.0760 | -0.3938 | 0.7590 | -0.1153 |
| $x_5$ | -0.2815 | -0.4793 | 0.7966 | 0.2191 | 0.0567 | -0.0727 |
| $x_6$ | -0.1111 | -0.8189 | -0.5567 | 0.0838 | 0.0111 | -0.0090 |

Como podemos observar, as cidades que tiveram uma predominância de votos na Situação (José Serra na época) tem valores de todos os quartis (1 quartil, mediana e 3 quartil) menores em comparação às cidades que tiveram uma predominância de votos na

Oposição (Lula na época), sendo assim, podemos ter um indicativo de que as cidades que tem uma estabilidade socioeconômica maior tiveram uma preferência de votos na oposição em 2002.

Outra coisa interessante é a análise dos outliers. Vemos pelo boxplot que, mesmo com a maioria dos outliers tendo valores mais negativos (puxando as métricas para baixo), há uma diferença significativa entre os valores da oposição ganhar ou não, evidenciando uma preferência de voto pelo índice de desenvolvimento socioeconômico (Fator 1) da cidade.

## Segundo fator principal

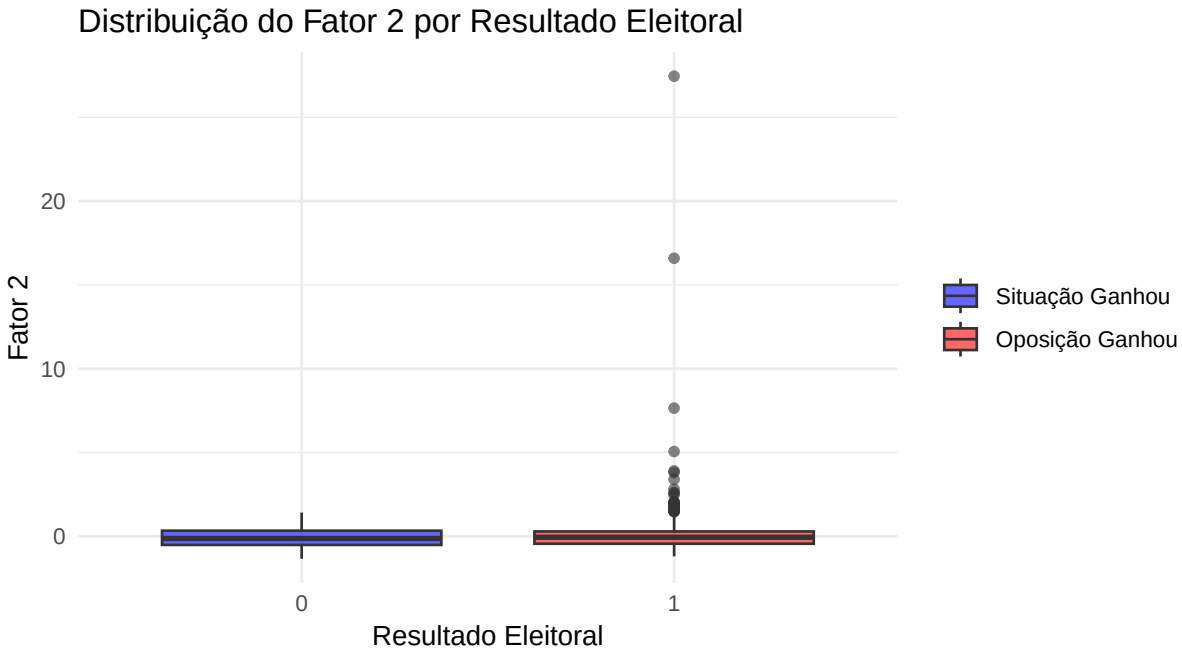


Figura 8: Boxplot dos escores fatoriais em relação ao segundo fator principal

| Estatística | OposicaGanha = 0 | OposicaGanha = 1 |
|---|---|---|
| Mínimo | -3.373289 | -3.1338 |
| 1º Quartil | -0.885684 | -0.3813 |
| Mediana | 0.005159 | 0.2034 |
| Média | -0.238597 | 0.1211 |
| 3º Quartil | 0.519372 | 0.7227 |
| Máximo | 3.183243 | 3.5528 |

Tabela 15: Estatísticas descritivas para PC1 divididas por OposicaGanha.

Pelo que podemos ver nessa comparação de boxplots, não existe uma diferença visível significativa entre os dois. Porém, ao analisar as métricas, vemos que, onde a oposição

ganha, obtém, em seu todo, métricas mais elevadas (mesmo com a diferença sendo baixa). Isso indicaria, de início, uma preferência de voto nas cidades mais populosas.

Entretanto, ao analisar os outliers, contradizemos esse ponto. Embora as métricas sejam maiores onde a oposição ganha, a análise dos outliers mostra que todos casos contribuem para o aumento dos valores e, mesmo assim, a diferença não é expressiva. Isso contrasta com o primeiro fator, onde todos os outliers atuam contra o aumento das métricas, mas a diferença entre os grupos ainda é mais significativa. Portanto, com base nesse ponto, optamos por considerar o Fator 2 como não significativo para o nosso objetivo.

# Conclusão

Neste estudo, foi realizada uma análise fatorial de duas dimensões, envolvendo as cidades da Região Sudeste, com o intuito de entender a relação entre fatores socioeconômicos, de saúde e características populacionais com as preferências eleitorais das cidades. A primeira dimensão, identificada como fator socioeconômico e de saúde, revelou uma associação com o voto na oposição, onde as cidades que optaram por esse caminho apresentaram valores mais elevados neste fator. Já a segunda dimensão, que refletia uma característica populacional, não demonstrou influência significativa nas preferências eleitorais, a não ser as cidades que tinham uma população muito maior que as das demais cidades, indicando que, apesar de sua relevância nas análises, a composição populacional não foi um diferencial decisivo nas escolhas políticas das cidades.
Esses achados sugerem que fatores socioeconômicos e de saúde podem ser determinantes na formação das atitudes políticas nas cidades da região, enquanto as características demográficas, pelo menos neste contexto, não desempenham um papel tão importante.

# Referências Bibliográficas

https://www.jornaldejales.com.br/jornal/editorial/26/06/2024/oposicao-ou-situaca
https://ava2.ead.ufscar.br/pluginfile.php/1308338/mod_resource/content/1/CREx1.txt
https://www.overleaf.com/project/677e7cba9902f8b30862ae74

```
#OBS: CÓDIGO COMPLETO (NÃO ESTÁ NA ORDEM)
library ("psych")
library("dplyr")
library ("GPArotation")

## Selecionando as variáveis quantitativas
library(readxl)
DadosS <- read_excel("C:/Users/tutui/Downloads/DadosS.xlsx")
Dados1=DadosS[,8:16]
```

```
Dados1
d1 = Dados1[,3]
d2 = Dados1[,5:9]
dados2 = cbind(d1,d2)
dados2 <- na.omit(dados2)
### Cálculo das  médiase desvios-padrõesdos dados

media= (cbind(mean(dados2$IDHM), mean(dados2$IDHL), mean(dados2$IDHE),mean(dados2$A
round(media[1,],2)

cov1=cov(dados2)
desvio=sqrt(diag(cov1))
round(desvio,2)

### Cálculo das Correlações
corr1 = cor(dados2)
round(corr1,3)

## Gráfico das Correlações

library ("corrplot")
col <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD", "#4477AA"))
corrplot(corr1, method="circle", col=col(200),
         type="upper",
         addCoef.col = "black", # Add coefficient of correlation
         tl.col="black", tl.srt=45, #Text label color and rotation
)


eigen(corr1)
### KMO e MSA ####

### Todas as Variáveis

KMO(dados2)

##############################################################################

### Análise Fatorial - Todas Variáveis - Dois Fatores

Fa2<-principal(dados2, nfactors=2, n.obs=1668,rotate="none",scores=T)
```

```
Fa2


## Cargas Fatorias e Comunalidades

round(Fa2$loadings,3)
round(Fa2$communality,3)

# Carregar pacotes necessários
library(ggplot2)
library(factoextra)

# Dados simulados das correlações dos componentes principais
# Criando o data frame original
# Criando o data frame
correlations <- data.frame(
  Variable = c("IDHM", "IDHL", "IDHE", "Alfab00","Medico00", "Pop2000"),
  PC1 = c(0.98, 0.77, 0.94, 0.94, 0.54, 0.21),
  PC2 = c(-0.10, -0.30, -0.04, -0.09, 0.50, 0.86)
)




# Criar o círculo unitário
theta <- seq(0, 2 * pi, length.out = 100)
circle <- data.frame(x = cos(theta), y = sin(theta))

# Gráfico com ggplot2
ggplot() +
  geom_path(data = circle, aes(x, y), color = "black", linetype = "dashed") + # Cír
  geom_segment(data = correlations, aes(x = 0, y = 0, xend = PC1, yend = PC2),
               arrow = arrow(length = unit(0.2, "cm")), color = "blue") + # Setas d
  geom_text(data = correlations, aes(x = PC1, y = PC2, label = Variable),
            vjust = 1, hjust = 1, color = "black") + # Nomes das variáveis
  coord_fixed() + # Manter proporção
  labs(title = "Correlação dos Componentes Principais",
       x = "PC1", y = "PC2") +
  theme_minimal()
```

```
#### Diagrama de Caminhos  ###

fa.diagram(Fa2, cut=0.5)

escores = Fa2$scores
# Criar um data frame com os escores
escores_df <- as.data.frame(escores)
escores_df$Observacao <- rownames(escores_df)

# Gráfico com ggplot2(MODIFICAÇÃO DO CÓDIGO ORIGINAL: APENAS COLOCAMOS OS NOMES DE
ggplot(escores_df, aes(x = PC1, y = PC2, label = Observacao)) +
  geom_point(color = "blue") +
  geom_text(vjust = -0.5, size = 3) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "black") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "black") +
  labs(title = "Gráfico dos Escores Fatoriais", x = "Fator 1", y = "Fator 2") +
  theme_minimal()


plot(eigen(corr1)$values,type="b", ylab="Autovalores",
     main="Scree Plot - Correlação Pearson")


pca_result <- principal(dados2, nfactors = 2, rotate = "varimax")

# Exibir os loadings rotacionados
print(pca_result, cutoff = 0.3)

varimax <- data.frame(
  var = c("IDHM", "IDHL", "IDHE", "Alfab00","Medico00", "Pop2000"),
  RC1 = c(0.97,0.82,0.91,0.92,0.36,-0.05),
  RC2 = c(0.19,-0.06,0.24,0.19,0.64,0.88)
)

theta <- seq(0, 2 * pi, length.out = 100)
circle <- data.frame(x = cos(theta), y = sin(theta))

# Gráfico com ggplot2
ggplot() +
  geom_path(data = circle, aes(x, y), color = "black", linetype = "dashed") + # Cír
  geom_segment(data = varimax, aes(x = 0, y = 0, xend = RC1, yend = RC2),
```

```
                arrow = arrow(length = unit(0.2, "cm")), color = "blue") + # Setas d
  geom_text(data = varimax, aes(x = RC1, y = RC2, label = var),
            vjust = 1, hjust = 1, color = "black") + # Nomes das variáveis
  coord_fixed() + # Manter proporção
  labs(title = "",
       x = "PC1", y = "PC2") +
  theme_minimal()


# Adicionando a variável de oposição ganhou aos escores fatoriais
escores_df$OposicaGanha <- DadosS$OposicaGanha



#Screeplot Escores Municipio + situacao oposicao
ggplot(escores_df, aes(x = PC1, y = PC2, color = as.factor(OposicaGanha))) +
  geom_point(alpha = 0.7, size = 3) +
  geom_text(aes(label = DadosS$Nome), vjust = -0.5, hjust = 0.5, size = 3) +  # Adi
  scale_color_manual(values = c("blue", "red"), labels = c("Situação Ganhou", "Opos
  labs(title = "Distribuição dos Escores Fatoriais",
       x = "Fator 1",
       y = "Fator 2") +
  theme_minimal() +
  theme(legend.title = element_blank())


# Boxplot do Fator 1 por situação/oposição
ggplot(escores_df, aes(x = as.factor(OposicaGanha), y = PC1, fill = as.factor(Oposi
  geom_boxplot(alpha = 0.6) +
  scale_fill_manual(values = c("blue", "red"), labels = c("Situação Ganhou", "Oposi
  labs(title = "Distribuição do Fator 1 por Resultado Eleitoral",
       x = "Resultado Eleitoral",
       y = "Fator 1") +
  theme_minimal() +
  theme(legend.title = element_blank())


# Boxplot do Fator 2 por situação/oposição
ggplot(escores_df, aes(x = as.factor(OposicaGanha), y = PC2, fill = as.factor(Oposi
  geom_boxplot(alpha = 0.6) +
  scale_fill_manual(values = c("blue", "red"), labels = c("Situação Ganhou", "Oposi
```

```
  labs(title = "Distribuição do Fator 2 por Resultado Eleitoral",
       x = "Resultado Eleitoral",
       y = "Fator 2") +
  theme_minimal()


  escores_grupo0 <- subset(escores_df, OposicaGanha == 0)
escores_grupo1 <- subset(escores_df, OposicaGanha == 1)
# Calcular o summary para cada grupo
summary(escores_grupo0)
summary(escores_grupo1)
```